

Determinantes del precio de la vivienda en Sevilla: un enfoque interpretativo con aprendizaje automático

Recibido: 2025-05-15

Aceptado: 2026-01-12

Cómo citar este artículo:

Gutiérrez, E., Caridad López del Río, L., y Caridad Ocerín, J. M. (2026). Determinantes del precio de la vivienda en Sevilla: un enfoque interpretativo con aprendizaje automático. *Revista INVI*, 41(116), 203-243.

<https://doi.org/10.5354/0718-8358.2026.78941>

Emiliano Gutiérrez

Instituto de Ciencias e Ingeniería de la Computación ICIC, Universidad Nacional del Sur, Consejo Nacional de Investigaciones Científicas y Técnicas, Argentina,

emiliano.gutierrez@uns.edu.ar

 <https://orcid.org/0000-0002-6424-996X>

Lorena Caridad López del Río

Departamento de Economía Financiera y Dirección de Operaciones, Universidad de Sevilla, España, lcaridad@us.es

 <https://orcid.org/0000-0002-3406-9917>

José María Caridad Ocerín

iManagement & Tourism, Sevilla, España,

ccjm@uco.es

 <https://orcid.org/0000-0003-4558-6618>



Determinantes del precio de la vivienda en Sevilla: un enfoque interpretativo con aprendizaje automático

Resumen

Este artículo analiza los factores asociados al precio de oferta de los apartamentos en la ciudad de Sevilla. Para ello se utiliza una base de datos de 1.710 anuncios recopilados en línea, incorporando características estructurales de las viviendas, indicadores socioeconómicos a nivel de sección censal y variables de proximidad a servicios locales. Se estiman dos modelos: una regresión hedónica mediante mínimos cuadrados ordinarios (MCO) y un modelo de *random forest*. Los resultados muestran que *random forest* alcanza un desempeño predictivo superior, reduciendo tanto el error absoluto medio como el error cuadrático medio respecto del modelo lineal. Además, el uso de técnicas de interpretabilidad (valores SHAP, curvas ICE y gráficos PDP) permite examinar la contribución de cada atributo en la predicción del precio. Las variables socioeconómicas (como la renta media y la proporción de población con estudios superiores) desempeñan un papel central en la variación espacial del precio de oferta, junto con las características estructurales de la vivienda. El estudio destaca la utilidad de combinar enfoques hedónicos con herramientas de aprendizaje automático para comprender mejor los determinantes del valor residencial en mercados urbanos.

Palabras clave: aprendizaje automático, mercado inmobiliario, modelo hedónico, vivienda, Sevilla (España).



Determinants of Housing Prices in Seville: An Interpretative Approach Using Machine Learning

Abstract

This article analyzes the factors associated with the asking prices of apartments in the city of Seville. For this purpose, we use a database of 1,710 listings collected online, including structural characteristics of the dwellings, socioeconomic indicators at the census-tract level, and variables of proximity to local services. Two models are estimated: a hedonic regression using ordinary least squares (OLS) and a random forest model. The results show that random forest achieves a higher predictive performance, reducing both the mean absolute error and the root mean squared error compared to OLS. In addition, the use of interpretability techniques (SHAP values, ICE curves, and PDP plots) makes it possible to examine the contribution of each attribute to predicted prices. Socioeconomic variables (such as average income and educational attainment) play a central role in explaining spatial variation in asking prices, together with structural characteristics of the dwellings. The study highlights the usefulness of combining hedonic modelling with machine learning tools to better understand the determinants of housing values in urban markets.

Keywords: machine learning, real estate market, hedonic model, dwelling, Seville (Spain).



Determinantes do preço da habitação em Sevilha: uma abordagem interpretativa com aprendizado de máquina

Resumo

Este artigo analisa os fatores associados ao preço de oferta de apartamentos na cidade de Sevilha. Para isso, utiliza-se uma base de dados com 1.710 anúncios coletados online, incorporando características estruturais das habitações, indicadores socioeconômicos no âmbito do setor censitário e variáveis de proximidade a serviços locais. Estimam-se dois modelos: uma regressão hedônica por mínimos quadrados ordinários (MQO) e um modelo de *random forest*. Os resultados indicam que o *random forest* alcança um desempenho preditivo superior, reduzindo tanto o erro médio absoluto quanto o erro quadrático médio em relação ao modelo linear. Além disso, o uso de técnicas de interpretabilidade (valores SHAP, curvas ICE e gráficos PDP) permite examinar a contribuição de cada atributo na previsão do preço. As variáveis socioeconômicas (como a renda média e a proporção da população com ensino superior) desempenham um papel central na variação espacial do preço de oferta, juntamente com as características estruturais da habitação. O estudo destaca a utilidade de combinar abordagens hedônicas com ferramentas de aprendizado de máquina para compreender melhor os determinantes do valor residencial em mercados urbanos.

Palavras-chave: aprendizado de máquina, mercado imobiliário, modelo hedônico, habitação, Sevilha (Espanha).

Introducción

La vivienda es un bien esencial que cumple una función central en la vida cotidiana, no solo como espacio físico para habitar, sino que también como componente clave del gasto de los hogares y principal activo patrimonial de muchas familias, siendo su precio un indicador relevante en cualquier análisis de la situación macroeconómica de un país (Martínez Pagés y Maza, 2003).

Su importancia económica y social ha sido reconocida a nivel nacional, considerando a la vivienda digna y adecuada como un derecho de raigambre constitucional, mientras que en el plano internacional su relevancia se refleja en *La nueva agenda urbana* (2020), que propone la necesidad de un análisis detallado y desagregado de la oferta y la demanda de vivienda a escalas nacional, subnacional y local, considerando características sociales, económicas y culturales. Este enfoque se vincula directamente con el objetivo de desarrollo sostenible nro. 11 de la Agenda 2030, que promueve ciudades inclusivas, seguras, resilientes y sostenibles (United Nations, 2015).

En España, en los últimos años el mercado inmobiliario ha mostrado signos de recuperación tras la pandemia de COVID-19 (Reglero, 2022), con un aumento sostenido de las transacciones residenciales entre 2021 y 2024 (Montoriol Garriga y Álvarez Ondina, 2025). Sin embargo, cerca del 90 % de estas operaciones corresponden a viviendas de segunda mano, lo que pone en evidencia una oferta limitada de obra nueva (Lajer Baron *et al.*, 2024). Esta escasez ha generado un desajuste entre oferta y demanda que, según estimaciones recientes, requeriría al menos duplicar el ritmo de construcción de vivienda para equilibrar el mercado (Zaragoza e Ibáñez, 2024). Asimismo, es importante enfatizar que este mercado se encuentra liberalizado por lo que la mayor parte de operaciones son efectuadas a través de particulares y el Estado cumple un rol secundario (Echaves García, 2017).

Específicamente, la ciudad de Sevilla, la quinta ciudad con mayor población del país (Instituto Nacional de Estadística, 2021), presenta como característica motivadora de esta investigación la alta presencia de una demanda impulsada por el alquiler turístico durante las últimas décadas. Esta presión sobre los precios dificulta la accesibilidad a la vivienda para la población local, especialmente en barrios tradicionales donde el auge de los alquileres turísticos ha transformado el tejido social (Díaz Parra, 2009; Jover y Díaz-Parra, 2022).

En este contexto, el estudio del mercado inmobiliario no solo permite una adecuada valorización de los inmuebles, sino que también contribuye a una asignación más eficiente de recursos, favoreciendo la transparencia y la competitividad en las transacciones. Tradicionalmente, estas valoraciones se han realizado mediante modelos hedónicos que asumen relaciones lineales entre el precio y las características de la vivienda. Así, el precio de un inmueble puede explicarse a partir de la valoración de las distintas características que lo componen, resultando el uso de modelos de precios hedónicos útil para estimar el valor implícito de cada atributo individual.

No obstante, el desarrollo e implementación de algoritmos de aprendizaje automático ha permitido formular modelos más flexibles, capaces de capturar relaciones no lineales y mejorar la capacidad predictiva.

Asimismo, la expansión del comercio electrónico ha abierto nuevas posibilidades para investigar mercados específicos a partir de la información disponible en línea. La generación constante de datos en entornos digitales, impulsada por la actividad de los usuarios, se ha convertido en una fuente valiosa para el análisis de fenómenos socioeconómicos con un nivel de granularidad y precisión previamente inalcanzables. Esta transformación en el acceso a la información ha facilitado el monitoreo de dinámicas complejas que, mediante enfoques tradicionales, habrían requerido recursos significativos o habrían resultado difíciles de abordar.

El presente trabajo tiene como objetivo desarrollar modelos que permitan estimar el precio de oferta de los apartamentos en la ciudad de Sevilla, así como identificar y analizar los principales factores que inciden en su valor. Para ello, se construirán dos modelos: uno basado en una estimación lineal mediante mínimos cuadrados ordinarios (MCO); otro, correspondiente a un algoritmo de aprendizaje automático, concretamente *random forest*. Dado el interés en comprender los mecanismos internos de este último, se adoptará un enfoque agnóstico que facilite la interpretación de sus resultados. Asimismo, se evaluará el desempeño predictivo de ambos modelos.

Este análisis se sustenta a partir de la recopilación de anuncios de venta publicados en línea, los cuales se integrarán con diversas fuentes de datos públicas con el fin de formular modelos que integren tantos aspectos propios de la vivienda como de su entorno.

A continuación, se describe la estructura de la investigación. En primer lugar, se presenta un apartado dedicado a los antecedentes relevantes, focalizándose en el caso español. En una segunda sección, se detallan las fuentes de datos utilizadas y los algoritmos empleados en el análisis. Los resultados derivados de la aplicación de los modelos estimados se exponen en una tercera sección, los cuales serán discutidos en un cuarto apartado. Finalmente, en la última sección se exponen las principales conclusiones del estudio.

Literatura relevante

La vivienda, como bien compuesto, deriva su precio de la combinación de múltiples atributos que el mercado valora de forma diferenciada. Uno de los primeros aportes se remonta a Lancaster (1966); este postuló una relación lineal entre el precio y las características del bien, con el objetivo de inferir las preferencias de los consumidores. Posteriormente, Rosen (1974) formalizó este enfoque introduciendo la noción de precio hedónico o implícito como herramienta analítica. En el contexto específico de la valorización de viviendas, Ridker y Henning (1967) realizan la primera contribución empírica, estimando el impacto negativo de la contaminación ambiental sobre los precios de las propiedades en el área metropolitana de St. Louis (Estados Unidos).

En el caso de España, este tipo de modelizaciones ha permitido analizar el efecto de distintas externalidades sobre el mercado inmobiliario. De este modo, Guijarro (2019) analiza el impacto del tráfico vehicular sobre los precios de vivienda en el área metropolitana de Madrid. Este estudio combina información de más de 21.000 anuncios inmobiliarios con datos de 3.094 puntos de medición de tráfico. El modelo de regresión aplicado considera al logaritmo natural del precio como la variable dependiente e incorpora tanto variables estructurales de las viviendas como dos indicadores clave relacionados con el tráfico: la distancia al punto de medición más cercano y el volumen de tráfico diario registrado en dicho punto. Los resultados revelan que la proximidad a los puntos de medición de tráfico ejerce un efecto positivo sobre los precios –posiblemente asociados a una mayor accesibilidad–, mientras que el volumen promedio de tráfico diario muestra un impacto negativo, reflejando la pérdida de valor causado por externalidades negativas como la contaminación acústica y atmosférica.

Esta evaluación de externalidades aplicada a los espacios verdes es abordada por Bengochea Morancho (2003) quien estima para la región de Castellón un modelo hedónico con una base de 810 observaciones. Mediante una especificación lineal considera variables propias del aspecto de la vivienda, y tres variables predictoras vinculadas a los espacios verdes: distancia al más próximo, su superficie y si es visible desde el inmueble, siendo el precio de este último la variable a predecir. Como principal hallazgo, encuentra una relación positiva entre precio de la vivienda y proximidad al espacio verde, destacando la relevancia de incorporar pequeños espacios verdes en el planeamiento urbano frente a un único parque extenso.

El efecto de las áreas verdes sobre los precios inmobiliarios también es analizado por Ramírez-Juidías *et al.* (2022), quienes estudian para la ciudad de Sevilla el impacto de la misma sobre el precio de la vivienda. Haciendo uso de 1000 observaciones, los autores contrastan especificaciones lineal, recíproca y logarítmica mediante MCO, incorporando tanto atributos propios de la vivienda como una medida de la dotación verde por habitante en cada distrito. El mejor desempeño obtenido corresponde al modelo lineal, identificando una relación positiva entre el valor del metro cuadrado y la disponibilidad de infraestructura verde dentro del ejido urbano.

Rey Simeón (2018) estudia también el mercado residencial de Sevilla. En este caso, se estima un modelo hedónico con MCO con 835 observaciones correspondientes al año 2017. Su especificación incorpora 49 predictores que recogen características estructurales, de localización y atributos específicos de cada inmueble, mostrando cómo estos factores se asocian de manera diferenciada con el precio de la vivienda.

Otra externalidad que motiva la implementación de modelos hedónicos viene dada por el trabajo de Céspedes-Lopez *et al.* (2020), trabajo que analiza el impacto de las certificaciones energéticas para los precios de viviendas en Alicante, utilizando una muestra de 52.939 propiedades. Utilizando como variable dependiente el logaritmo natural del precio y 62 variables explicativas, los autores encuentran que las viviendas con certificados de alta eficiencia no obtienen primas de precio significativas; no obstante, las que ocultan su calificación se venden a precios similares a las eficientes. Esto revelaría falta de incentivos para mejorar la eficiencia energética, debido a la escasa fiscalización normativa y la percepción negativa de los compradores de viviendas certificadas. En un trabajo posterior, Céspedes-Lopez *et al.* (2022) analizan la

misma externalidad mediante modelos estimados por Mínimos Cuadrados Ordinarios y técnicas multinivel con dos niveles jerárquicos: características individuales de la vivienda y atributos del área geográfica. Los resultados obtenidos darían cuenta de que la interacción entre etiquetas energéticas y factores contextuales puede modificar el efecto de la calificación energética sobre el precio.

El impacto de la eficiencia energética en el mercado inmobiliario es también abordado por Marmolejo-Duarte *et al.* (2024) quienes examinan la evolución de los factores que influyen en el valor de la vivienda en Barcelona. Estimando dos modelos lineales para el año 2020 y 2023 con una base de 10.958 observaciones, incorporan características estructurales, variables de localización, indicadores de calidad arquitectónica y la calificación energética de los inmuebles. La comparación entre ambos periodos muestra variaciones en el impacto de estos atributos, con una mayor incidencia de la eficiencia energética y de la calidad del edificio.

Asimismo, la ampliación de la red de transporte público es la motivación del trabajo de Mejía Dorantes *et al.* (2011) investigan el impacto económico de la nueva línea de metro Metrosur (Línea 12) en los precios de vivienda en cinco municipios del sur de Madrid. El estudio emplea modelos hedónicos espaciales. Específicamente se estiman modelizaciones de rezago espacial (SLM) y de error espacial (SEM) para analizar cómo la proximidad a las estaciones de metro afecta el valor de las propiedades, considerando variables estructurales de ubicación y de accesibilidad a partir de 1.714 observaciones recopiladas en línea. Los resultados revelan que una mayor cercanía a las estaciones de Metrosur tiene un efecto positivo en los precios, aunque este beneficio varía según el municipio y la zona tarifaria.

Por su parte, García (2006), haciendo uso de la información de ventas de una agencia inmobiliaria junto con bases de datos de organismos oficiales, estima para Málaga un modelo hedónico con una especificación log-lineal mediante MCO. Utilizando un total de 25 variables explicativas de los resultados obtenidos, el autor distingue entre factores estructurales tales como la cantidad de habitaciones, estacionamiento privado y acceso a luz natural, los cuales tendrían un impacto significativo sobre el precio de una vivienda. Por otra parte, aquellas variables asociadas a las localizaciones vinculadas a la proximidad al mar, al centro de la ciudad y con desarrollo económico, cultural y ambiental, se encuentran asociadas a los inmuebles de mayor valor.

Chica-Olmo y Cano-Guervos (2020) estudian el mercado inmobiliario de Granada utilizando una base de 3.882 viviendas, a partir de la cual estiman un modelo hedónico con variables estructurales, cuya localización y características son específicas del inmueble. Sobre esta estimación aplican posteriormente técnicas de *regression-kriging*. El enfoque permite descomponer el precio en un componente explicado por los atributos de la vivienda y otro asociado a la dependencia espacial del entorno inmediato. Los resultados muestran que la inclusión de *kriging* mejora la capacidad explicativa del modelo respecto a la regresión hedónica tradicional, identificando primas y descuentos relativos entre viviendas que no se captan únicamente con los predictores observables.

Mora-García *et al.* (2019) analizan los determinantes del precio de las viviendas de segunda mano en la provincia de Alicante, utilizando una muestra de 34.138 viviendas obtenidas de un portal inmobiliario. Aplican modelos de regresión hedónica por MCO y regresión cuantílica, haciendo uso de 39 variables explicativas. Destacan, entre las variables más influyentes, la superficie construida, el número de baños, la existencia de ascensor, piscina, plaza de garaje y la localización en áreas costeras o de mayor nivel educativo, donde la regresión cuantílica evidencia que el efecto de muchas variables no es uniforme.

Si bien el enfoque tradicional hedónico que usa modelos lineales ha demostrado utilidad, presenta desafíos econométricos a resolver. La multicolinealidad entre predictores –particularmente en variables de localización y accesibilidad– puede distorsionar la estimación de parámetros (Yazdani, 2021). A esto se agregan problemas de especificación funcional, heterocedasticidad y sensibilidad a *outliers* (Solano Sánchez *et al.*, 2021), limitaciones que han motivado la incorporación de técnicas de aprendizaje automático al mercado inmobiliario.

Así algunos estudios exponen la divergencia entre la tradicional regresión lineal hedónica y métodos propios del aprendizaje automático. Caridad y Ceular (2001), luego de haber analizado 1.057 transacciones en Córdoba, encuentran que las redes neuronales artificiales (RNA) superan el ajuste de los modelos lineales tradicionales. Resultados similares son obtenidos por Núñez Tabales *et al.* (2016) utilizando un conjunto de datos en línea de 698 avisos de Sevilla, donde usan como variables explicativas índices multidimensionales procesados mediante RNA, mostrando mejor desempeño que MCO en todos los indicadores globales evaluados.

La combinación entre métodos de aprendizaje automático junto con estimaciones econométricas hedónicas y espaciales es abordado en Rey-Blanco *et al.* (2024), quienes desarrollan un modelo de dos etapas para segmentar mercados inmobiliarios en Madrid, Barcelona y Valencia, combinando árboles de decisión con funciones interactivas y modelos hedónicos espaciales, en particular especificaciones autorregresivas espaciales (SAR). El estudio analiza 44.270 observaciones en Madrid, 23.334 en Barcelona y 14.018 en Valencia. Para esto se vale de 13 variables explicativas, incluyendo atributos de la vivienda (como área construida, número de habitaciones y amenidades) y asociados a la localización (distancia a centros urbanos, estaciones de metro y avenidas principales).

Por su parte, Baldominos *et al.* (2018) contrasta el rendimiento y la estimación hedónica mediante MCO con una variedad de algoritmos propios del aprendizaje automático. Analizando información recopilada en internet sobre avisos de venta en Salamanca durante el primer semestre de 2017, realizan una regresión lineal hedónica junto con *random forest*, *support vector machine* (SVM), K-Vecinos más cercanos (KNN) y RNA, utilizando 18 variables explicativas y encontrando que todos estos modelos superan notablemente a la regresión lineal en la predicción de la valorización de una vivienda.

Por su parte, Guijarro (2023) analiza la valoración automática de inmuebles residenciales en la ciudad de Madrid utilizando distintos modelos de aprendizaje automático, haciendo uso de una base de 17.486 viviendas, y un total de 12 variables explicativas divididas en atributos físicos, socioeconómicos y de localización. Se entrenan modelos de *gradient boosting machine* (GBM), XGBoost, RNA y modelos lineales generalizados, donde GBM resultó ser el modelo que presenta mayor poder predictivo.

Fuera del caso español, pero dentro del contexto europeo, se identifican diversos estudios orientados a evaluar la predicción de precios en el mercado de la vivienda mediante algoritmos de aprendizaje automático. En el caso de Italia, Rampini y Re Cecconi (2022) analizan dos localidades: Brescia, donde emplean un conjunto de datos con 1.203 viviendas, y Varese, con 1.228 observaciones. Los autores aplican tres técnicas de aprendizaje automático (ElasticNet, XGBoost y RNA) y evalúan el desempeño mediante el MAE, observando que la RNA obtiene los mejores resultados en ambas ciudades.

Por su parte, Štubňová *et al.* (2020) analizan los precios de apartamentos en Nitra (Eslovaquia) a partir de 256 observaciones obtenidas en un portal inmobiliario. Estiman un modelo hedónico mediante MCO con 12 variables explicativas y lo comparan con diversas arquitecturas de RNA, encontrando que estas últimas presentan un rendimiento superior. Entre las variables con mayor influencia destacan la superficie, el número de habitaciones, la planta y el estado del edificio.

De manera similar, Deaconu *et al.* (2022) estudian los precios de venta de apartamentos en Cluj-Napoca (Rumanía) utilizando 900 transacciones del segundo semestre de 2019 y un conjunto inicial de 33 atributos físicos, de localización y de vecindario, de los cuales 22 se incorporan finalmente al modelo. Comparan un modelo hedónico estimado mediante MCO con RNA y concluyen que esta última mejora la capacidad predictiva.

Para Francia, Tchuente y Nyawa (2022) analizan el mercado de vivienda en nueve ciudades utilizando datos oficiales de ventas (2015–2019) y siete algoritmos de aprendizaje automático (RF, RNA, GBM, KNN, AdaBoost y Support Vector Machine). Inicialmente estiman los modelos sin información espacial y, posteriormente, incorporan latitud y longitud, lo que produce una mejora promedio del 36 % en todas las métricas. En Lille, la ciudad con los mejores resultados, el algoritmo RF exhibe el mayor poder predictivo.

Sin embargo, uno de los principales problemas asociados a la aplicación de algoritmos de aprendizaje automático radica en su naturaleza de «caja negra» (Caridad y Ceular, 2001), donde el énfasis recae en su implementación y evaluación del rendimiento predictivo, sin analizar las decisiones subyacentes que determinan dichas predicciones. La interpretación de resultados no solo permite obtener predicciones más precisas, sino también identificar qué información resulta relevante y cuál no, lo que simplifica el proceso de recolección de datos. Asimismo, la transparencia en el funcionamiento de los parámetros del modelo no solo facilita su ajuste para optimizar el rendimiento, sino que también genera mayor confianza tanto en los desarrolladores como en los usuarios finales (Ribeiro *et al.*, 2016). Para lograr esto, resulta fundamental adoptar un enfoque agnóstico, que permita interpretar los resultados independientemente del algoritmo de aprendizaje automático utilizado (Molnar, 2020).

Diversos estudios han aplicado técnicas de interpretabilidad a la valorización de inmuebles. En el ámbito nacional, Rico-Juan y Taltavull de La Paz (2021) analizaron el mercado inmobiliario de Alicante utilizando 392.412 observaciones proporcionadas por una empresa de tasaciones para el período 2004-2012. Los autores evaluaron múltiples algoritmos, identificando que *random forest* presentaba el mejor desempeño predictivo. Este modelo fue posteriormente analizado en términos de explicabilidad mediante valores de

Shapley. Al comparar estos resultados con una estimación hedónica tradicional (MCO), se detectaron diferencias significativas entre los coeficientes más relevantes en la regresión lineal y los atributos prioritarios según *random forest*. Los autores sugieren que esta discrepancia evidencia la presencia de no linealidades que solo son capturadas mediante herramientas de interpretabilidad propias del aprendizaje automático, lo que podría mejorar sustancialmente las estimaciones en el mercado inmobiliario.

Mora-García *et al.* (2022) analizan el rendimiento predictivo durante 2020 y 2021 en el contexto del COVID-19 para esta misma provincia, señalando que la flexibilidad de los modelos de aprendizaje automático puede ayudar a explicar los cambios que experimentó el mercado inmobiliario durante este período. Utilizando como variable a predecir el logaritmo del precio, 28 variables explicativas y 39.943 avisos de venta online, estiman modelos de *ensemble learning* basados en *boosting* (Gradient Boosting Regression, Xgboost, *light gradient boosting machine*) y *bagging* (*random forest*, Extra-Tree Regression), junto la regresión lineal hedónica. Asimismo, mediante técnicas de permutación de atributos y *partial dependence plot* (PDP), identifican las variables más influyentes sobre el precio, siendo las mismas la superficie, número de baños, ascensor y ubicación.

De esta forma, la amplia variedad de estudios vinculados a la valorización del precio de la vivienda presenta una notable heterogeneidad relacionada a la complejidad de los métodos aplicados. En la Tabla 1 se presentan los modelos que presentaron un mejor ajuste en cada uno de los estudios abordados en esta sección. Aunque los mismos no son estrictamente comparables por la heterogeneidad en variables, muestras y métricas, permiten obtener una noción general de los enfoques metodológicos predominantes y de su desempeño.

Metodología y datos

Los datos recopilados para esta investigación fueron obtenidos el día 8 de marzo del 2025 a través del portal Fotocasa. Para esto fue necesaria la implementación de un programa de *web scraping* que recopilase de manera sistemática toda la información contenida en este sitio web. La totalidad de observaciones válidas –luego de preprocesada la información– fue de 1.710, habiendo sido relevados exclusivamente apartamentos.

Si bien los datos proceden de anuncios publicados en un portal inmobiliario, reflejando, por lo tanto, precios de oferta, esta clase de fuentes se ha convertido en un insumo habitual para el análisis del mercado residencial, especialmente en estudios urbanos de alta desagregación espacial. La literatura metodológica reconoce que pueden existir diferencias entre el precio de oferta y su efectivo precio de cierre, así como ciertos sesgos derivados del proceso de publicación, aunque también documenta su utilidad para capturar la dinámica del mercado y la heterogeneidad intraurbana (Gila y Novás, 2012; “Handbook on residential property”, 2013; Instituto Nacional de Estadística, 2017; Sánchez-Cabrera *et al.*, 2024). Del mismo modo, Rey-Blanco *et al.* (2024) analiza en detalle las particularidades muestrales y los procedimientos de depuración

habituales en portales inmobiliarios, así como su utilidad para capturar la dinámica espacial del mercado y las precauciones necesarias al trabajar con precios de oferta.

Los atributos recuperados fueron agrupados en cuatro categorías, como se detallan en la Tabla 2. Una primera categoría refiere a las características estructurales del inmueble y que son propias de su construcción; un segundo agrupamiento corresponde a las amenidades que puede presentar la vivienda o el edificio y que resultarían beneficiosas para las condiciones de vida de los residentes.

Debido a que la información provista en el portal se encontraba geolocalizada, una tercera categoría de variables refiere a la distancia más próxima de cada vivienda tanto a paradas de autobuses, estaciones de metro, hospitales, universidades y policía local, siendo necesario el entrecruzamiento de datos públicos provenientes de la web del Instituto de Estadística de Cartografía de Andalucía y del Portal de Datos Abiertos de Esri España.

Un cuarto agrupamiento, considera el perfil socioeconómico correspondiente a la localización de cada apartamento. De esta forma, se consideran características vinculadas al máximo nivel de educación, longevidad, migración y renta dentro de cada sección censal donde se halla ubicado el inmueble, utilizando datos públicos del Anuario Estadístico de la ciudad de Sevilla y del Instituto Nacional de Estadística.

De esta forma, el total de variables relevadas asciende a 18. El conjunto total de datos se encuentra armonizado y disponible en un repositorio de Github¹

En la Figura 1 se presenta el histograma de precios (en euros). Se observa una marcada dispersión y, a partir de valores superiores a 400.000 €, la frecuencia de inmuebles comienza a decrecer.

¹ https://github.com/LW6EGE/Sevilla_app

Tabla 1.

Síntesis de estudios sobre modelos de valorización del precio de la vivienda en España y Europa.

Estudio	Ámbito geográfico	Variable dependiente	Mejor modelo	Métricas
<i>Localizados en España. Variable dependiente: Precio (€)</i>				
Bengochea Morancho (2003)	Castellón	Precio (€)	MCO	$R^2=0,748$; R^2 ajust.=0,743
Mejia Dorantes <i>et al.</i> (2011)	Madrid	Precio (€)	SLM	$R^2=0,765$
Ramírez-Juidías <i>et al.</i> (2022)	Sevilla	Precio (€)	MCO	$R^2=0,721$
Núñez Tabales <i>et al.</i> (2016)	Sevilla	Precio (€)	RNA	$R^2=0,891$; MAE=28.222; MAPE=0,165; RMSE=37.732,02
Rey Simeón (2018)	Sevilla	Precio (€)	MCO	$R^2=0,82$; R^2 ajust=0,82
Caridad y Ceular (2001)	Córdoba	Precio (€)	RNA	$R^2=0,822$; MSE=3.552,12
Baldominos <i>et al.</i> (2018)	Salamanca	Precio (M€)	KNN	$R^2=0,36$; MAE=0,44
<i>Localizados en España. Variable dependiente: Ln(precio)</i>				
Guijarro (2019)	Madrid	Ln(precio)	MCO	$R^2=0,9437$
Céspedes-Lopez <i>et al.</i> (2020)	Alicante	Ln(precio)	MCO	$R^2=0,716$
Céspedes-Lopez <i>et al.</i> (2022)	Valencia	Ln(precio)	MCO	$R^2=0,726$
García (2006)	Málaga	Ln(precio)	MCO	$R^2_{adj}=0,83$
Mora-García <i>et al.</i> (2019)	Alicante	Ln(precio)	MCO	$R^2=0,731$
Chica-Olmo y Cano-Guervos (2020)	Granada	Ln(precio)	Kriging	$R^2=0,733$; MSE=0,281
Rey-Blanco <i>et al.</i> (2024)	Madrid	Ln(precio)	SAR	MAE=0,176; RMSE=0,242; MAPE=0,014
Rey-Blanco <i>et al.</i> (2024)	Barcelona	Ln(precio)	SAR	MAE=0,167; RMSE=0,227; MAPE=0,013

Estudio	Ámbito geográfico	Variable dependiente	Mejor modelo	Métricas
Rey-Blanco <i>et al.</i> (2024)	Valencia	Ln(precio)	SAR	MAE=0,191; RMSE=0,253; MAPE=0,016
Rico-Juan y Taltavull de La Paz (2021)	Alicante	Ln(precio)	RF	R ² =0,985; RMSE=0,078; MAE=0,03
Mora-García <i>et al.</i> (2022)	Alicante	Ln(precio)	GBM	R ² =0,919; RMSE=0,182; MAE=0,126
Guijarro Martínez (2023)	Madrid	Ln(precio)	GBM	RMSE=0,171; MSE=0,0292; MAPE=0,122
<i>Localizados fuera de España. Variable dependiente: Precio (€)</i>				
Rampini y Re Cecconi (2022)	Brescia	Precio (€)	RNA	MAE=77.015
Rampini y Re Cecconi (2022)	Varese	Precio (€)	RNA	MAE=56.128
Štubňová <i>et al.</i> (2020)	Nitra	Precio (€)	RNA	R ² =0,975; RMSE=6.241,13; MAE=3.561,29; MAPE=0,0339
Deaconu <i>et al.</i> (2022)	Cluj-Napoca	Precio (€)	RNA	R ² =0,8051; RMSE=17.162,74
Tchuente y Nyawa (2022)	Lille	Precio (€)	RF	R ² =0,80; MAE=30.225; RMSE=47.992


Fuente: elaboración propia.

Tabla 2.
Listado total de atributos recuperados.

	Variable	Tipo	Descripción	Fuente
Estructurales	precio	Numérica	Precio de oferta del aviso publicado (en euros).	Fotocasa
	superficie	Numérica	Área total del apartamento (en m ²).	
	habitaciones	Numérica	Número de habitaciones.	
	bano	Numérica	Número de baños.	
Amenidades	ascensor	Binaria	Presencia de ascensor (1) o ausencia del mismo (0).	Fotocasa
	aire_acond	Binaria	Presencia de aire acondicionado (1) o ausencia del mismo (0).	
	balcón	Binaria	Presencia de balcón (1) o ausencia del mismo (0).	
	terraza	Binaria	Presencia de terraza (1) o ausencia del mismo (0).	
Proximidad geográfica	hospital	Numérica	Distancia al hospital más cercano (en km).	Instituto de Estadística y Cartografía de Andalucía
	metro	Numérica	Distancia a la estación de metro más cercana (en km).	
	universidad	Numérica	Distancia la universidad más cercana (en km).	
	autobus urbano	Numérica	Distancia a la estación de autobús urbano más cercana (en km).	
	autobus Interurbano	Numérica	Distancia al a la estación de autobús más cercana (en km).	
	policia_local	Numérica	Distancia a algún destacamento de policía local (en km).	Portal de Datos Abiertos Esri España
Socioeconómicas	renta	Numérica	Renta media por habitante dentro de la sección censal.	Anuario Estadístico de la Ciudad de Sevilla
	longevidad	Numérica	Proporción de adultos mayores (más de 65 años) dentro de la sección censal.	Instituto Nacional de Estadística
	presion_mig	Numérica	Proporción de individuos con extranjeros de la sección censal.	
	educ_sup	Numérica	Proporción de individuos con educación superior dentro de la sección censal.	

Fuente: elaboración propia.


Figura 1.
Histograma por precio (en euros).



Fuente: elaboración propia.

Del mismo modo, en la Figura 2, se presenta la distribución correspondiente a la superficie, pudiéndose observar que el mayor segmento de inmuebles se corresponde con las propiedades de entre 100 y 150 m².


Figura 2.
Histograma por superficie.



Fuente: elaboración propia.

En lo que refiere a la distribución del valor por metro cuadrado, el mismo se presenta en la Figura 3. Siendo relevante que Triana y Nervión son los barrios cuyo precio por m² superan en algunas zonas más de 4000 €.

Figura 3.
Distribución del precio por m² (en euros).



Fuente: elaboración propia.

El modelo a estimar es entendido como una función dependiente del precio tal como

$$precio_i = F(\text{estructurales, amenidades, proximidad geográfica, socioeconómicos})$$

Donde para un apartamento el precio es explicado por los agrupamientos de variables considerados en la Tabla 2.

Una de las estimaciones a efectuar consiste, entonces, en la tradicional regresión mediante MCO, la cual expone de manera lineal la relación entre precio y las variables que determinan el mismo, siendo planteado como

$$precio_i = \beta_0 + \beta X_i + u_i$$

Donde corresponde al término error aleatorio de cada observación y al vector de variables explicativas.

En este tipo de modelos aplicados a precios de vivienda es habitual la posible presencia de autocorrelación espacial en los residuos, ya que las viviendas cercanas pueden compartir factores no observados. En este trabajo no se estima un modelo hedónico espacial por lo que los resultados del MCO deben interpretarse como una aproximación global. La inclusión de variables socioeconómicas a nivel de sección censal y la estimación adicional por distritos ayudan a relevar parte de esa dependencia espacial.

El segundo modelo a estimar corresponde a *random forest*. Desarrollado por Breiman (2001), este algoritmo, propone el uso de un número suficientemente grande de árboles interrelacionados con el fin de mejorar la predicción final. Mediante la agregación por *bootstrapping* se selecciona aleatoriamente un número de observaciones sobre las cuales se estima con una colección de árboles para los cuales el promedio de los mismos dará como resultado el valor ofertado del inmueble, esto es:

$$F(X) = \frac{1}{J} \sum_{j=1}^J h_j(X_i)$$

Donde corresponde a la cantidad total de árboles a utilizar. Por otra parte, es importante señalar que *random forest* no utiliza la totalidad de las variables explicativas, haciendo uso, como es típico, de la regla como la cantidad de predictoras a utilizar en la generación de cada árbol (Cutler *et al.*, 2012). Tanto la no utilización del conjunto total de datos como de una parte de las variables explicativas tienen por consecuencia que este algoritmo permita generalizar los resultados obtenidos, siendo especialmente útil en el caso de efectuar predicciones (Hastie *et al.*, 2009).

En el caso de *random forest*, las variables de proximidad geográfica y del entorno socioeconómico permiten captar patrones espaciales en la predicción del precio. Sin embargo, este modelo tampoco incorpora de forma explícita un término de autocorrelación espacial en los residuos, por lo que su aporte debe entenderse como complementario al de los modelos hedónicos espaciales.

Una de las técnicas a utilizar a fin de interpretar los resultados derivados de la aplicación de *random forest*, corresponde a *Shapley additive explanations* (SHAP). Desarrollada a partir del aporte de Shapley (1953), la propuesta de SHAP posteriormente implementada por Lundberg y Lee (2017) permite determinar cómo y de qué forma contribuyen las variables explicativas al modelo mediante coaliciones de las mismas al momento de efectuar una predicción. Los valores SHAP ofrecen dos ventajas principales: por un lado, permiten establecer un orden de importancia entre los distintos atributos del modelo y, por otro lado, posibilitan evaluar el tipo de impacto (positivo o negativo) que cada variable ejerce sobre la variable dependiente. Esta doble capacidad de SHAP lo convierte en una herramienta particularmente valiosa para la interpretación de modelos complejos de aprendizaje automático aplicados al mercado inmobiliario.

Otro método de interpretabilidad a utilizar al momento de analizar los resultados provenientes de *random forest* son las gráficas de *partial dependence plot* (PDP) las cuales permiten visualizar la dependencia de una variable respecto a los valores de otra variable específica (Friedman, 2001), pudiendo mostrar si la relación entre dos variables es lineal, monótona o más compleja (Molnar, 2020), mediante un promedio de las predicciones sobre el conjunto de datos, considerando como constantes al resto de variables explicativas.

Sin embargo, un aspecto de interés refiere a la interacción que pueden tener las variables predictivas entre sí cuando no existe linealidad. Para esto se recurrirá al estadístico H de Friedman, el cual evalúa hasta qué punto el efecto conjunto de dos o más predictores difiere de la suma de sus efectos individuales (Friedman y Popescu, 2008).

Asimismo, para evaluar el desempeño predictivo tanto de las estimaciones por MCO como *random forest*, se utilizarán algunas métricas que permitan tener en cuenta tanto la magnitud de los errores como la capacidad explicativa del modelo. Para esto se hará uso del error absoluto medio (MAE) el cual proporciona una medida robusta del error promedio en las unidades originales de la variable respuesta. En términos del modelo a plantear en esta investigación puede entenderse como el error medio en euros al predecir el precio de cada vivienda.

Otra métrica menos sensible a valores atípicos y errores grandes es la raíz del error cuadrático medio (RMSE), que eleva al cuadrado el error de cada predicción. El RMSE penaliza con más peso los errores grandes, por lo que es útil para detectar si el modelo falla en algunos casos concretos. Complementariamente, el error porcentual absoluto medio (MAPE) expresa la precisión media en porcentaje de la predicción respecto de su valor real. El MAPE resume ese error medio en porcentaje sobre el valor observado, lo que facilita la comparación con otros estudios. Además, el coeficiente de determinación (R^2) a utilizar, cuantificará la proporción de la varianza explicada por el modelo, donde valores cercanos a 1 indican un ajuste óptimo, mientras que cuanto más bajo sea su valor resultará ser más deficiente el ajuste de los datos.

Resultados

La implementación de los modelos fue realizada siguiendo una estrategia de validación cruzada (*cross-validation*) con 10 pliegues (*folds*), siendo seleccionado como óptimo aquel modelo que presentó un menor MAE.

En la Tabla 3 se presentan los resultados relativos a la estimación por MCO la cual fue efectuada a través de la librería *statsmodels* (Seabold y Perktold, 2010) correspondiente al lenguaje de programación Python.

La bondad de ajuste obtenida (R^2) da cuenta de que un 79 % de la variabilidad en el precio se explica por las variables independientes del modelo. Sin embargo, la estimación mostró valores extremadamente altos de factor inflacionario de varianza (FIV) en algunas variables (*longevidad*, *educ_sup*, *renta*, *superficie* y *habitaciones*), lo que refleja la presencia de correlaciones entre atributos y limita la estabilidad de los coeficientes del modelo lineal.

Asimismo, en lo que refiere a los aspectos estructurales de la vivienda, un m² adicional (*superficie*) implica un aumento en el precio de 1284,52€, mientras que para un baño (*bano*) también existe una relación positiva donde cada uno de los mismos incrementa el valor ofertado en 41835 €. Por otra parte, en el caso de las habitaciones (*habitaciones*) esta variable presenta signo negativo y no supera el umbral de significatividad del 95 %.

Para las amenidades que puede poseer un apartamento, contar con ascensor (*ascensor*), aire acondicionado (*aire_acond*), balcón (*balcon*) y/o terraza (*terrazza*) se traduce en un mayor precio ofertado, siendo la existencia de ascensor el que mayor impacto presenta sobre el precio, incrementando el valor de una vivienda en 25454 €.

De las variables asociadas a la proximidad, la cercanía a universidades (*universidad*), paradas de autobuses interurbanos (*autobus_interurbano*) y locales (*autobus_local*) y estaciones de policía local (*policia_local*), se asocian positivamente con el precio. Es decir, un mayor alejamiento de estas ubicaciones implica una caída en el valor ofertado del inmueble. De manera opuesta en el caso de las estaciones de metro (*metro*), la proximidad a la misma se traduce en un menor valor. Asimismo, en el caso de la variable destinada a relevar la distancia al hospital (*hospital*), la misma resulta no ser significativa.

Observando los atributos vinculados a las condiciones socioeconómicas, la renta media correspondiente al radio censal donde se halla localizada la vivienda (*renta*), presenta un impacto positivo sobre su precio. Esta relación positiva también se detecta en el caso de la proporción de habitantes que tienen estudios de nivel superior (*educ_sup*) dentro de la sección censal. Por otra parte, no superan el umbral de significatividad al 95 % las variables destinadas a relevar la presión migratoria (*presion_mig*) como la proporción de adultos mayores (*longevidad*) sobre la sección censal.

Tabla 3.
Resultados de la estimación por MCO

	Coefficiente	Error estándar	t-valor	p-valor	FIV
Constante	-47545,68	17393,78	-2,73	0,01*	
superficie	1284,52	68,87	18,65	0,00*	18,794
Habitaciones	-3032,02	2261,07	-1,34	0,18	16,790
bano	41835,13	3638,56	11,50	0,00*	13,621
ascensor	25454,31	3563,34	7,14	0,00*	2,424
aire_acond	22470,19	3462,54	6,49	0,00*	2,140
balcón	10385,24	4462,10	2,33	0,02*	1,269
terrazza	9147,85	3547,13	2,58	0,01*	1,803
hospital	-2242,66	5973,80	-0,38	0,71	5,359
metro	4252,44	2037,47	2,09	0,04*	9,607
universidad	-16886,86	2531,46	-6,67	0,00*	6,517
autobus_interurbano	-12973,19	2884,36	-4,50	0,00*	9,047
autobus_local	-13452,30	3990,21	-3,37	0,00*	3,754
policia_local	-8383,48	3732,04	-2,25	0,02*	6,958
renta	6,34	1,94	3,27	0,00*	236,034
longevidad	-497,71	289,92	-1,72	0,09	23,814
educ_sup	2345,18	489,67	4,79	0,00*	115,068
presion_mig	-785,14	426,56	-1,84	0,07	3,007
Variable dependiente:	Precio	Numero de observaciones	1538		
R ² :	0,790	AIC:	382374		
R ² ajustado:	0,788	BIC:	383334		
Log-Likelihood:	- 19101	Estadístico F	336.1		
G.L. modelo	19	Prob (estadístico F):	0,00		
G.L. residuos	1519				
*: Significativo al 95 %					

Tabla 4.
Ajuste del modelo MCO por distrito.

Distrito	n	R ² ajustado
Bellavista - La Palmera	146	0,888
Casco Antiguo	219	0,611
Cerro - Amate	267	0,796
Este - Alcosa - Torreblanca	163	0,764
Los Remedios	45	0,623
Macarena	160	0,773
Nervión	150	0,701
Norte	108	0,582
San Pablo - Santa Justa	164	0,799
Sur	141	0,835
Triana	145	0,757

Fuente: elaboración propia.

Como análisis adicional, se estimaron modelos MCO independientes para cada uno de los once distritos administrativos con el propósito de evaluar hasta qué punto la heterogeneidad territorial podría modificar la estructura de los determinantes del precio de oferta. Los valores del R² ajustado para cada distrito se presentan en la Tabla 4, situándose entre 0,58 y 0,89, lo que indica un buen nivel de ajuste en todos los casos.

Asimismo, la Tabla 5 resume la cantidad de distritos en los que cada variable presenta coeficientes positivos significativos, negativos significativos o no significativos al 95 %. En las variables estructurales, la superficie (*superficie*) resulta significativa en los once distritos y baños (*banos*) en la mayoría de ellos, mientras que la cantidad de habitaciones (*habitaciones*) no presenta significancia en ninguno. Entre las amenidades, disponer de ascensor (*ascensor*) y aire acondicionado (*aire_acond*) son asociados positivamente al precio en varios distritos, aunque su efecto no es uniforme. Las variables de proximidad geográfica y las socioeconómicas muestran patrones de significancia más dispersos y sin un comportamiento común entre distritos.


Por otra parte, el modelo mediante *random forest*, fue estimado mediante el paquete *Scikit-learn* (Pedregosa *et al.*, 2011) correspondiente al lenguaje de programación Python. Debido a la necesidad de lograr un ajuste que posibilite el mejor rendimiento predictivo de este algoritmo, fue necesario evaluar el desempeño mediante una búsqueda en rejilla (*grid search*), donde la selección de los hiperparámetros con 500 árboles se realizó con un máximo de cuatro variables explicativas por árbol, un mínimo de una observación por hoja y al menos dos observaciones para dividir el árbol.

Tabla 5.
Signo y significancia (95 %) de los coeficientes por distrito.

Variable	+	-	No significativo
aire_acond	6	0	5
ascensor	8	0	3
autobus_interurbano	1	0	10
autobus_local	1	0	10
balcon	2	0	9
bano	9	0	2
educ_sup	0	1	10
habitaciones	0	0	11
hospital	1	2	8
longevidad	0	3	8
metro	1	0	10
policia_local	2	2	7
presion_mig	0	3	8
renta	2	0	9
superficie	11	0	0
terraza	4	0	7
universidad	1	0	10

Fuente: elaboración propia.

Figura 4.
Valores SHAP (random forest).



Fuente: elaboración propia.

La Figura 4 muestra los valores SHAP obtenidos de la implementación de *random forest*, ordenados según su relevancia. Los resultados revelan que las variables con mayor impacto positivo sobre el precio están relacionadas con el perfil socioeconómico: específicamente, la proporción de habitantes con estudios superiores (*educ_sup*) y renta media (*renta*) de la sección censal. La superficie del inmueble (*superficie*), es también otro de los atributos que destaca de manera esperable, donde una mayor área de la vivienda implica un precio más alto de la misma. Es seguido por otra predictora asociada a las condiciones estructurales de la vivienda como lo es la cantidad de baños (*bano*), siendo todos estos casos, resultados similares a los obtenidos por MCO.

De igual modo para las amenidades (*ascensor*, *terraza*, *balcón aire_acond*), se replica su influencia sobre el precio observado en el caso de la estimación por MCO. Una situación similar ocurre con la distancia a universidades y a las paradas de autobuses más cercanas.

Como atributos que presentan una diferencia con las estimaciones derivadas de MCO se resalta el caso de la cantidad de habitaciones (*habitaciones*), donde este algoritmo daría cuenta de una relación positiva entre habitaciones y precio. Asimismo, en el caso del porcentaje de población con más de 65 años (*longevidad*) y distancia a hospitales (*hospital*) no quedaría del todo claro su impacto sobre el precio.


Otro atributo de interés es la presión migratoria (*presion_mig*) dentro de la sección censal donde se localiza el inmueble. A diferencia del modelo lineal, en este caso una mayor proporción de migrantes se asocia a un menor precio de la vivienda.

Una variable con un resultado particularmente distinto al obtenido en el modelo por MCO es la distancia de paradas del metro (*metro*), donde evaluando su comportamiento frente a valores SHAP, se observa que una mayor proximidad se traduce en un mayor precio ofertado.

La Figura 5 resume de forma gráfica el efecto de las variables más importantes según el modelo de *random forest*. Cada gráfico muestra cómo cambia el precio estimado al modificar tan solo una variable (manteniendo constantes las demás).

Asimismo, el análisis de las gráficas PDP permite evaluar el impacto específico de estas variables sobre el precio, tal como se exhiben en la Figura 5. En estos gráficos se pretende reflejar el cambio en el precio estimado cuando se modifica una sola de estas variables y el resto se mantiene constante en los valores observados. La línea central recoge el efecto medio (PDP) y las curvas individuales representan el comportamiento de cada vivienda (ICE). Así, en el caso de la renta media (*renta*) se observa un aumento del precio a partir de los niveles más altos de ingreso; para la superficie la relación es casi lineal, mientras que para la cantidad de baños (*bano*) el salto se da al pasar de un baño a dos. En habitaciones (*habitaciones*) el incremento de precio se concentra al pasar de dos a tres dormitorios; a partir de cuatro, el efecto adicional es prácticamente nulo.


Figura 5.
Curvas ICE y PDP.



Fuente: elaboración propia.

Figura 6.

Interacción general. Estadístico H de Friedman (random forest).



Fuente: elaboración propia.

Asimismo, la distancia al metro (*metro*) presenta un comportamiento no lineal, con una reducción notoria en el precio a partir de los dos kilómetros de distancia. Mientras que, en cuanto al impacto de la proporción de adultos mayores (*longevidad*) en donde se ubica la vivienda, no se detecta una relación específica con el mismo.

Adquiere relevancia en este punto comprender cómo se producen las interacciones entre los predictores al momento de estimar el precio que presenta un apartamento en el caso de *random forest*. En la Figura 6, se exhibe el estadístico H de Friedman a fin de estimar la interacción general que presentan los diez atributos más relevantes, permitiendo evaluar hasta qué punto el efecto de una variable depende de las demás. Valores bajos indican que la variable actúa casi de forma independiente, mientras que valores más altos señalan una interacción importante con otros predictores. Se destacan así, tanto la renta media (*renta*) de la sección censal como el área (*superficie*).

Sin embargo, la dinámica de estos atributos se vincula individualmente con el resto de las variables explicativas. Así, en la Figura 7 se analiza la interacción individual de la variable destinada a relevar la renta media (*renta*). Allí se muestra con qué variables se combina con más fuerza esta variable cuando el modelo estima el precio. Dicha variable presenta la mayor interacción con otros atributos vinculados a las características socioeconómicas de la ubicación, como lo es la proporción de personas con estudios superiores (*educ_sup*), y también la proximidad de la universidad (*universidad*).


Del mismo modo, en la misma Figura 8 se presenta la interacción de la variable destinada a relevar el área del apartamento (*superficie*). Se destaca que, además de la renta media (*renta*) y la proporción de estudios universitarios (*educ_sup*), esta predictora tiene su mayor interacción con la cantidad de baños del inmueble (*bano*), siendo también el número de habitaciones (*habitaciones*) una de las predictoras de mayor importancia.

La comparación del desempeño predictivo entre *random forest* respecto de la estimación mediante MCO es señalada en la Tabla 6. En ambos casos se presenta el promedio para cada pliegue al momento de aplicar validación cruzada. En la Tabla 6 se resumen las métricas obtenidas a partir de la validación cruzada. Independientemente de la métrica a considerar, *random forest* presenta un rendimiento superior.

En términos de MAE, el modelo MCO exhibe un valor de 45.153,9 €, mientras que en *random forest* se reduce a 32.143,9 €, es decir, una diferencia de algo más de 13.000 euros por vivienda. El RMSE también es menor en *random forest*, lo que indicaría que los errores más grandes son menos frecuentes en este modelo. En el caso del MAPE, en promedio, las predicciones del MCO se desvían un 27,8 % del precio observado, mientras que en *random forest* ese desvío medio baja al 19,6 %. En el caso del R^2 y del R^2 ajustado, los valores pasan de 0,788 y 0,786 en el modelo MCO a 0,870 y 0,869 en *random forest*, lo que indica que este último explica una proporción mayor de la variación del precio de oferta.

Figura 7.


Interacción individual del atributo renta. Estadístico H de Friedman (random forest)



Fuente: elaboración propia.

Figura 8.

Interacción individual del atributo superficie. Estadístico H de Friedman (random forest).



Fuente: elaboración propia.

Tabla 6.
Desempeño del modelo. Promedio de validación cruzada (10 pliegues).

Métrica	MCO	Random forest
RMSE	60373,004	47101,796
MAE	45153,876	32143,873
R ²	0,788	0,870
R ² ajustado	0,786	0,869
MAPE	0,278	0,196

Fuente: elaboración propia.

Discusión

El sector inmobiliario constituye un ámbito de especial relevancia en el análisis de los mecanismos de formación de precios, dado que la vivienda representa uno de los activos de mayor valor económico dentro del patrimonio de los hogares.

La utilización de datos digitales en este campo facilita el estudio de los factores determinantes del valor de las propiedades, al permitir el procesamiento de un volumen de información significativamente mayor en comparación con las metodologías tradicionales de recolección. No obstante, al igual que ocurre en cualquier investigación basada en datos obtenidos mediante *web scraping*, surgen limitaciones relacionadas con la representatividad de la muestra, ya que no necesariamente refleja la totalidad del mercado. Además, se debe considerar un aspecto no menor: que los precios utilizados corresponden a precios de oferta, con las limitaciones ya discutidas en la sección de datos.

Como antecedentes aplicados al mercado residencial de Sevilla se destacan los trabajos de Rey Simeón (2018), Núñez Tabales *et al.* (2016) y Ramírez-Juidías *et al.* (2022), todos ellos basados en información procedente de anuncios en línea. En el caso de Núñez Tabales *et al.* (2016), la modelización compara un modelo hedónico con redes neuronales, obteniendo un R² de 0,89 en el mejor modelo obtenido mediante RNA haciendo uso de 698 observaciones. Por su parte, Ramírez-Juidías *et al.* (2022) emplean 1.000 observaciones para analizar el efecto de los espacios verdes mediante MCO y logran un R² de 0,72, mientras que Rey Simeón (2018)

estima un modelo hedónico con 835 observaciones y una especificación más extensa –con 49 predictores– alcanzando un R^2 de 0,82. Frente a estos antecedentes, el presente estudio emplea una base de datos con 1.710 observaciones, alcanzando un R^2 de 0,87 para el modelo estimado mediante *random forest*, superior al de las investigaciones de Rey Simeón (2018) y Ramírez-Juidías *et al.* (2022) y con valores próximo al trabajo de Núñez Tabales *et al.* (2016). Asimismo, para el ajuste y calibración del modelo efectuado en esta investigación se recurrió a validación cruzada, donde la métrica para medir el error considera específicamente el pliegue que el modelo no había utilizado en su entrenamiento.

En el caso de esta investigación, a fin de predecir el precio de oferta, *random forest* mejoró el poder predictivo respecto del modelo estimado por MCO. Esto puede explicarse ya que reduce sistemáticamente los errores de predicción y resulta menos afectado por la colinealidad, distribuyendo la información redundante a través de los distintos árboles. Como aspecto adicional y que también puede explicar la diferencia de performance, el ajuste de modelos MCO por distrito pone de manifiesto que el signo y la significancia de las variables cambian de forma importante entre distritos, lo que refuerza la idea de que los parámetros lineales son sensibles a la partición espacial y al conjunto concreto de predictores incluidos. Sin embargo, la literatura al respecto no presenta un consenso de la elección de un modelo óptimo. Algunos trabajos siguen confiando en especificaciones hedónicas clásicas (Bengochea Morancho, 2003; Céspedes-Lopez *et al.*, 2020, 2022; Chica-Olmo y Cano-Guervos, 2020; Garcia, 2006; Guijarro, 2019; Mejía Dorantes *et al.*, 2011; Mora-García *et al.*, 2019; Ramírez-Juidías *et al.*, 2022; Rey-Blanco *et al.*, 2024; Rey Simeón, 2018), mientras que otros encuentran mejoras claras con *random forest*, boosting o RNA (Baldominos *et al.*, 2018; Deaconu *et al.*, 2022; Mora-García *et al.*, 2022; Rico-Juan y Taltavull de La Paz, 2021; Štubňová *et al.*, 2020). En este contexto, el uso de *random forest* no pretendió sustituir al modelo lineal, sino complementar la aproximación hedónica clásica con una herramienta que capta mejor las no linealidades y sirve de base para aplicar técnicas de interpretabilidad.

En cuanto a las variables vinculadas con las condiciones estructurales de la vivienda, para superficie y cantidad de baños, en ambos casos se encontró una relación positiva respecto del precio tanto en la estimación de MCO como en *random forest*. En el caso concreto de Sevilla el aporte de Núñez Tabales *et al.* (2016) encuentra una relación positiva significativa entre área de un apartamento y su precio. Por otra parte, para ambos atributos, es similar al obtenido en otros trabajos aplicados a España (Caridad y Ceular, 2004; Caridad *et al.*, 2008; Céspedes-Lopez *et al.*, 2022; Garcia, 2006; Guijarro, 2019; Mora-García *et al.*, 2022; Rey-Blanco *et al.*, 2024) como también en trabajos para otras ciudades de Europa (Deaconu *et al.*, 2022; Rampini y Re Cecconi, 2022; Štubňová *et al.*, 2020; Tchunte y Nyawa, 2022).

Por otra parte, en cuanto a la cantidad de habitaciones, los resultados obtenidos en *random forest*, a partir de la gráfica PDP e ICE junto con los valores SHAP, darían cuenta de un impacto positivo sobre el precio. En la estimación mediante MCO presenta signo negativo y no supera el umbral de significatividad, resultado similar al obtenido por Guijarro (2019), exponiendo que una modelización lineal no sería ideal para este conjunto de datos. En línea con este hallazgo, Baldominos *et al.* (2018), al momento de estimar MCO sin controlar por heterocedasticidad, obtiene que el número de habitaciones se asocia de manera significativa y negativa con el precio. Del mismo modo, Rey Simeón (2018) encuentra un resultado similar para Sevilla, dando

cuenta que dicho resultado ocurre a partir de la fuerte correlación entre superficie y número de habitaciones. Desde esta perspectiva, para un mismo tamaño de vivienda, un número excesivo de habitaciones reduce los metros cuadrados por habitáculo y se asocia a pisos de menor calidad relativa y, por tanto, a precios más bajos. No obstante, también para Sevilla, Ramírez-Juidías *et al.* (2022) identifican el número de habitaciones como uno de los determinantes positivos. Una conclusión similar se desprende de Mora-García *et al.* (2019) quienes encuentran que el impacto de habitaciones varía según el tramo de precio, de modo que su importancia no es constante a lo largo de la distribución.

La presencia de amenidades, concretamente la existencia de ascensor, aire acondicionado, balcón y terraza revela la valoración positiva de estos atributos en las estimaciones realizadas, tanto según el modelo mediante MCO como según *random forest*. La influencia positiva de estas variables es también encontrada en los trabajos de Guijarro (2019), Mora-García *et al.* (2022), Bengochea Morancho (2003) y Rico-Juan y Taltavull de La Paz (2021).

Para el grupo de variables vinculadas a la proximidad geográfica –en lo que refiere a la distancia a estaciones de metro– el aporte de Rey-Blanco *et al.* (2024) encuentra una asociación positiva para esta variable respecto del precio, en las ciudades de Valencia y Madrid. En este caso las técnicas de interpretabilidad aplicadas en *random forest*, revelan que existe una valoración positiva frente a la cercanía de las estaciones, resultado opuesto al obtenido en MCO. En el caso del metro, *random forest* no identifica una relación lineal con el precio, sino un patrón donde los valores más altos se concentran en distancias intermedias. Esta forma responde a la heterogeneidad observada entre distritos y a que la proximidad al metro no presenta un comportamiento uniforme en los datos, donde el modelo lineal resulta limitado para capturar adecuadamente esta predictora, tal como muestran los resultados obtenidos. Una posible explicación a esta divergencia radica en la configuración particular de la red de metro de Sevilla, limitada a una única línea que atraviesa áreas con valores residenciales relativamente contenidos, mientras que zonas con precios elevados se apoyan en otros modos de transporte o en la cercanía al centro histórico.

Para este mismo grupo de variables, el impacto sobre el precio se vincula (en lo referente a la distancia sobre universidades, estaciones de autobuses y policía local) con la proximidad a las mismas, siendo esto detectado tanto en el caso del modelo por MCO como en *random forest*, revelando la valoración positiva en el precio frente a estas instituciones.

Cabe señalar que en el modelo lineal estimado los coeficientes negativos se asocian a la distancia, de modo que un mayor alejamiento implica una caída en el precio, por lo que la cercanía a universidades y paradas de autobús se corresponde con valores más altos. El análisis complementario de MCO por distrito refleja que estos efectos no son homogéneos espacialmente, lo que ayuda a explicar las diferencias observadas entre MCO y *random forest*. En el caso de la cercanía frente a las estaciones de policía la misma puede ser entendida como la valorización dada por la percepción de seguridad y baja incidencia del crimen (McIlhatton *et al.*, 2016), mientras que para las universidades la cercanía podría dar cuenta de una demanda generada por la presencia de estudiantes, siendo este un factor de presión adicional sobre el precio. Mora-García *et al.* (2022), estimando un modelo lineal, encuentran que aquellas viviendas dentro de un radio de un kilómetro

con la universidad presentan un mayor valor mientras que, al momento de aplicar diversos algoritmos de aprendizaje automático ese atributo sería uno de los más importantes.

En el caso de la proximidad a las paradas de autobús, se distinguió entre interurbano y urbano, siendo ambos coincidentes en cuanto a que su cercanía está asociada a un impacto positivo sobre el precio. Este resultado es coherente con el estudio de Rico-Juan y Taltavull de La Paz (2021), donde se encuentra una asociación significativa entre la cercanía a paradas de bus y el precio en una regresión hedónica cuantílica, observándose un efecto similar en todos los cuantiles analizados.

Respecto de la distancia al hospital, mientras que la estimación por MCO no daría cuenta de que dicha predictora superase el umbral de significatividad del 95 %, tampoco los valores SHAP serían concluyentes al respecto de su influencia sobre el precio, siendo este resultado opuesto al encontrado por Mejia Dorantes *et al.* (2011), quien para el caso de Madrid encuentra que la distancia al mismo se asocia a mayores precios. No obstante, este diferencial en el resultado podría explicarse por el tamaño que presenta Sevilla respecto de Madrid, por lo que distancias a centros hospitalarios podrían no ser relevantes al momento de determinar el precio ofertado por un inmueble. Por otra parte, Céspedes-Lopez *et al.* (2022), estudiando el mercado inmobiliario de Alicante y mediante estimaciones por MCO, encuentran que la lejanía al centro de salud se asocia a positivamente al precio.

Asociado al perfil socioeconómico, la renta media por sección censal fue el atributo que mayor importancia presentó en *random forest* al momento de analizar los valores SHAP, contribuyendo positivamente sobre el precio ofertado tanto en *random forest* como en MCO.

La relevancia de la renta media es resaltada por Mora-Garcia *et al.* (2022), quien encuentra que esta misma variable es la más relevante al momento de utilizar dos algoritmos de aprendizaje automático (*gradient boost regressor* y *extra tree regressor*). Del mismo modo, la renta media dentro del edificio es la tercera variable más relevante señalada por la investigación de Rico-Juan y Taltavull de La Paz (2021) al momento de examinar los valores SHAP dentro de su estimación de *random forest*.

Según los valores SHAP, el segundo atributo más importante es la proporción de habitantes con estudios superiores en la sección censal donde se ubica el apartamento. Esta variable muestra una relación positiva y significativa con el precio, coincidiendo con los resultados del modelo de MCO. Este resultado es conducente con el aporte de Mora-Garcia *et al.* (2019), quienes estiman tanto por MCO como regresión cuantílica encontrando en todos los casos que la proporción de graduados universitarios impacta positivamente sobre el precio.

Respecto de la presión migratoria, los resultados obtenidos no superan el umbral de significatividad en MCO, aunque en el caso de *random forest* darían cuenta de que el valor del mismo impacta negativamente sobre el precio. Sin embargo, estos hallazgos son diferentes a los encontrados en Mora-Garcia *et al.* (2019) como en Céspedes-Lopez *et al.* (2020), quienes estiman modelos lineales donde en ambos casos la proporción de migrantes dentro del vecindario presenta una relación positiva con el valor del inmueble.

La variable restante asociada al perfil socioeconómico fue la proporción de adultos mayores dentro de la sección censal, donde la estimación por MCO no presentó significatividad alguna, como tampoco en el caso de *random forest*, donde no existió un impacto claro sobre el precio. Sin embargo, este resultado es opuesto tanto al aporte de Mora-García *et al.* (2019) como al de Cespedes-Lopez *et al.* (2020), detectando que la proporción de adultos mayores sobre el vecindario presenta un impacto positivo sobre el valor de la vivienda.

Conclusión

El mercado inmobiliario presenta numerosas implicaciones, no solo comerciales sino que también sociales, siendo necesario el estudio de estas para la toma de decisiones de las políticas habitacionales destinadas a fortalecer la adopción de estrategias que contribuyan a un desarrollo urbano sostenible.

En el caso de esta investigación, se pretendió realizar una contribución al mercado inmobiliario de Sevilla, utilizando información en línea y mediante la aplicación tanto de métodos lineales como no lineales, formulándose un modelo lineal mediante MCO, similar a los tradicionales modelos hedónicos, en simultáneo con la implementación de un algoritmo de aprendizaje automático como lo es *random forest*; así se pudo observar el comportamiento de las variables explicativas considerando las no linealidades. En este último caso, se hizo uso de técnicas de interpretabilidad a fin de examinar el impacto de las variables explicativas utilizadas.

De esta manera, se relevaron más de 1.700 avisos de venta de apartamentos obtenidos en un portal inmobiliario. Dada la posibilidad de disponer de bases de datos complementarias, fue posible la inclusión de otros atributos relevantes para este mercado donde la variable de interés fue el precio, agrupándose las mismas en cuatro grupos de atributos: estructurales, amenidades, proximidad y socioeconómicas.

El impacto de la totalidad de variables vinculadas a las características estructurales de la vivienda como lo son la superficie, cantidad de habitaciones y baños presentó un impacto positivo asociado al precio. Del mismo modo, la presencia de las amenidades repercutió en un mayor valor del inmueble.

Para el caso de la proximidad, la cercanía a paradas de autobús urbano o interurbano, estaciones de metro y destacamentos de policía, se encuentran positivamente asociadas con el precio de oferta del apartamento. Para las categorías referidas a la situación socioeconómica, si bien las mismas presentaron impactos tanto positivos como negativos sobre el precio, se destacan tanto el nivel de renta media como el nivel de la educación superior como dos variables asociadas positivamente sobre el precio. Por otra parte, la presión migratoria presentó una asociación negativa con el valor de oferta del inmueble.

La utilización de ambos modelos debe entenderse como la aplicación de técnicas complementarias que permiten una mejor interpretación del impacto de los atributos para el precio de oferta de la vivienda. Por

otra parte, debe tenerse especial cuidado al interpretar estos resultados, ya que los mismos refieren al precio publicado, el cual no corresponde al precio de cierre de la operación de compraventa de la vivienda.

Asimismo, como líneas de investigación futura a partir de los datos utilizados, sería de interés la evaluación de otros modelos de aprendizaje automático a fin de contrastar estos mismos con los resultados obtenidos.

Finalmente, se subraya la importancia de estimar modelos de valorización de inmuebles enfocados en distintas regiones de España, con el objetivo de determinar si las dinámicas observadas responden a particularidades del mercado inmobiliario propio de Sevilla o si, por el contrario, pueden ser generalizables al ámbito nacional.

Financiamiento

Investigación financiada mediante AUIP y la Consejería de Universidad, Investigación e Innovación de la Junta de Andalucía. Código PMP-2025-18-020.

Declaración de autoría

Emiliano Gutiérrez: conceptualización, curación de datos, adquisición de fondos, investigación, metodología, visualización, redacción – borrador original, redacción – revisión y edición.

Lorena Caridad López del Río: adquisición de fondos, validación, recursos, redacción – borrador original, redacción – revisión y edición.

José María Caridad Ocerín: adquisición de fondos, redacción – borrador original, redacción – revisión y edición.

Referencias


- Baldominos, A., Blanco, I., Moreno, A. J., Iturrarte, R., Bernárdez, Ó., y Afonso, C. (2018). Identifying real estate opportunities using machine learning. *Applied Sciences*, 8(11), 2321. <https://doi.org/10.3390/app8112321>
- Bengochea Morancho, A. (2003). A hedonic valuation of urban green areas. *Landscape and Urban Planning*, 66(1), 35-41. [https://doi.org/10.1016/S0169-2046\(03\)00093-8](https://doi.org/10.1016/S0169-2046(03)00093-8)
- Breiman, L. (2001). Random forest. *Machine Learning*, 45, 5-32. <https://doi.org/10.1023/A:1010933404324>
- Caridad, J. M. y Ceular, N. (2001). Un análisis del mercado de la vivienda a través de redes neuronales artificiales. *Estudios de Economía Aplicada*, (18), 67-81.
- Caridad, J. M. y Ceular, N. (2004). Determinación de los precios implícitos en bienes inmuebles: una alternativa a la modelización hedónica. *Revista de Estudios Regionales*, (71), 85-105. <http://www.revistaestudiosregionales.com/documentos/articulos/pdf800.pdf>
- Caridad, J. M., Nuñez, J. M. N., y Ceular, N. C. (2008). Metodología de precios hedónicos vs. redes neuronales artificiales como alternativas a la valoración de inmuebles. Un caso real. *CT: Catastro*, (62), 27-42. https://www.catastro.hacienda.gob.es/documentos/publicaciones/ct/ct62/ct62_3.pdf
- Céspedes-Lopez, M. F., Mora-Garcia, R. T., Perez-Sanchez, V. R., y Marti-Ciriquian, P. (2020). The influence of energy certification on housing sales prices in the province of Alicante (Spain). *Applied Sciences*, 10(20), 7129. <https://doi.org/10.3390/app10207129>
- Céspedes-Lopez, M. F., Perez-Sanchez, V. R., y Mora-Garcia, R. T. (2022). The influence of housing location on energy ratings price premium in Alicante, Spain. *Ecological Economics*, 201, 107579. <https://doi.org/10.1016/j.ecolecon.2022.107579>
- Chica-Olmo, J. y Cano-Guervos, R. (2020). Does my house have a premium or discount in relation to my neighbors? A regression-kriging approach. *Socio-Economic Planning Sciences*, 72, 100914. <https://doi.org/10.1016/j.seps.2020.100914>
- Cutler, A., Cutler, D. R., y Stevens, J. R. (2012). Random forests. En C. Zhang y Y. Ma (Eds.), *Ensemble machine learning: Methods and applications* (pp. 157-175). Springer. https://doi.org/10.1007/978-1-4419-9326-7_5
- Deaconu, A., Buiga, A., y Tothăzan, H. (2022). Real estate valuation models performance in price prediction. *International Journal of Strategic Property Management*, 26(2), 86-105. <https://doi.org/10.3846/ijspm.2022.15962>
- Díaz Parra, I. (2009). Procesos de gentrificación en Sevilla en la coyuntura reciente. Análisis comparado de tres sectores históricos: San Luis-Alameda, Triana y San Bernardo (2000-2006). *Scripta Nova*, 13(304). <https://www.ub.edu/geocrit/sn/sn-304.htm>
- Echaves García, A. (2017). El difícil acceso de los jóvenes al mercado de vivienda en España: precios, regímenes de tenencia y esfuerzos. *Cuadernos de Relaciones Laborales*, 35(1), 127-149. <https://doi.org/10.5209/CRLA.54986>

- Friedman, J. H. (2001). Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, 29(5), 1189-1232. <https://doi.org/10.1214/aos/1013203451>
- Friedman, J. H. y Popescu, B. E. (2008). Predictive learning via rule ensembles. *The Annals of Applied Statistics*, 2(3), 916-954. <https://doi.org/10.1214/07-AOAS148>
- García, A. F. (2006, 30 de agosto). *Housing market in Malaga: An application of the hedonic methodology* [ponencia en congreso]. 46th Congress of the European Regional Science Association: Enlargement, Southern Europe and the Mediterranean, Volos, Grecia. <https://hdl.handle.net/10419/118208>
- Gila, A. y Novás, M. (2012). El uso del método hedónico para ajustar los cambios de calidad: la experiencia del IPV. *Estadística Española*, 54(179), 299-310.
- Guijarro, F. (2019). Assessing the impact of road traffic externalities on residential price values: A case study in Madrid, Spain. *International Journal of Environmental Research and Public Health*, 16(24), 5149. <https://doi.org/10.3390/ijerph16245149>
- Guijarro, F. (2023). Valoración automática de inmuebles residenciales mediante modelos de Machine Learning. *Revista de Estudios Empresariales*, (2), 27-40. <https://doi.org/10.17561/ree.n2.2023.7823>
- Handbook on residential property price indices (RPPIs)*. (2013). Publications Office of the European Union. <https://doi.org/10.1787/9789264197183-en>
- Hastie, T., Tibshirani, R., y Friedman, J. (2009). *The elements of statistical learning*. Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- Instituto Nacional de Estadística. (2017). *Índice de precios de vivienda. Base 2015. Metodología*. <https://www.ine.es/daco/daco42/ipv/metodologia2015.pdf>
- Instituto Nacional de Estadística. (2021). *Censo de población y viviendas 2021*. <https://ine.es/dynt3/inebase/es/index.htm?padre=8952&capsel=8953>
- Jover, J. y Díaz-Parra, I. (2022). Who is the city for? Overtourism, lifestyle migration and social sustainability. *Tourism Geographies*, 24(1), 9-32. <https://doi.org/10.1080/14616688.2020.1713878>
- La nueva agenda urbana ilustrada en español*. (2020). Centro Urbano, ONU-Habitat. <https://onu-habitat.org/index.php/la-nueva-agenda-urbana-en-espanol>
- Lajer Baron, A., López Rodríguez, D., y San Juan, L. (2024). El mercado de la vivienda residencial en España: evolución reciente y comparación internacional. *Documentos Ocasionales*, (2433). <https://doi.org/10.53479/37873>
- Lancaster, K. J. (1966). A new approach to consumer theory. *Journal of Political Economy*, 74(2), 132-157. <https://doi.org/10.1086/259131>
- Lundberg, S. M. y Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.

- Marmolejo-Duarte, C., Espinoza-Zambrano, P., y Biere-Arenas, R. (2024). Cambios en el impacto de la eficiencia energética, la centralidad y la calidad arquitectónica sobre los valores plurifamiliares en Barcelona 2020-2023. *Ciudad y Territorio Estudios Territoriales*, 56(222), 1283-1306. <https://doi.org/10.37230/CyTET.2024.222.10>
- Martínez Pagés, J. y Maza, L. Á. (2003). *Análisis del precio de la vivienda en España*. Banco de España. <https://www.bde.es/wbe/es/publicaciones/analisis-economico-investigacion/documentos-trabajo/analisis-precio-vivienda-espana.html>
- McIlhatton, D., McGreal, W., Taltavul de la Paz, P., y Adair, A. (2016). Impact of crime on spatial analysis of house prices: evidence from a UK city. *International Journal of Housing Markets and Analysis*, 9(4), 627-647. <https://doi.org/10.1108/IJHMA-10-2015-0065>
- Mejía Dorantes, L., Paez, A., y Vassallo, J. M. (2011). Analysis of house prices to assess economic impacts of new public transport infrastructure: Madrid metro line 12. *Transportation Research Record: Journal of the Transportation Research Board*, 2245(1), 131-139. <https://doi.org/10.3141/2245-16>
- Molnar, C. (2020). *Interpretable machine learning: A guide for making black box models explainable*. LeanPub. <https://christophm.github.io/interpretable-ml-book/>
- Montoriol Garriga, J. y Álvarez Ondina, P. (2025). *El mercado residencial español se adentra en una nueva fase expansiva*. CaixaBank. <https://www.caixabankresearch.com/es/analisis-sectorial/inmobiliario/mercado-residencial-espanol-se-adentra-nueva-fase-expansiva>
- Mora-García, R. T., Cespedes-Lopez, M. F., y Perez-Sanchez, V. R. (2022). Housing price prediction using machine learning algorithms in COVID-19 times. *Land*, 11(11), 2100. <https://doi.org/10.3390/land11112100>
- Mora-García, R. T., Cespedes-Lopez, M. F., Perez-Sanchez, V. R., Martí, P., y Perez-Sanchez, J. C. (2019). Determinants of the price of housing in the province of Alicante (Spain): Analysis using quantile regression. *Sustainability*, 11(2), 437. <https://doi.org/10.3390/su11020437>
- Núñez Tabales, J. M., Rey Carmona, F. J., y Caridad y Ocerin, J. M. (2016). Artificial intelligence (AI) techniques to analyze the determinants attributes in housing prices. *Inteligencia Artificial*, 19(58), 23-38. <https://doi.org/10.4114/ia.v19i58.1156>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830. <https://www.jmlr.org/papers/v12/pedregosa11a.html>
- Ramírez-Juidías, E., Amaro-Mellado, J. L., y Leiva-Piedra, J. L. (2022). Influence of the urban green spaces of Seville (Spain) on housing prices through the hedonic assessment methodology and geospatial analysis. *Sustainability*, 14(24), 16613. <https://doi.org/10.3390/su142416613>
- Rampini, L. y Re Cecconi, F. (2022). Artificial intelligence algorithms to predict Italian real estate market prices. *Journal of Property Investment & Finance*, 40(6), 588-611. <https://doi.org/10.1108/JPIF-08-2021-0073>
- Reglero, J. (2022). *Evolución actual del mercado inmobiliario en España y reseñas sobre Latam*. OBS Business School.

- Rey Simeón, S. d. (2018). *Un análisis econométrico del precio de la vivienda en Sevilla en el año 2017* [proyecto máster, Universidad de Sevilla]. idUS. <https://hdl.handle.net/11441/86407>
- Rey-Blanco, D., Arbués, P., López, F. A., y Páez, A. (2024). Using machine learning to identify spatial market segments. A reproducible study of major Spanish markets. *Environment and Planning B: Urban Analytics and City Science*, 51(1), 89-108. <https://doi.org/10.1177/23998083231166952>
- Ribeiro, M. T., Singh, S., y Guestrin, C. (2016). *Model-agnostic interpretability of machine learning*. arXiv. <https://doi.org/10.48550/arXiv.1606.05386>
- Rico-Juan, J. R. y Taltavull de La Paz, P. (2021). Machine learning with explainability or spatial hedonics tools? An analysis of the asking prices in the housing market in Alicante, Spain. *Expert Systems with Applications*, 171, 114590. <https://doi.org/10.1016/j.eswa.2021.114590>
- Ridker, R. G. y Henning, J. A. (1967). The determinants of residential property values with special reference to air pollution. *The review of Economics and Statistics*, 49(2), 246-257. <https://doi.org/10.2307/1928231>
- Rosen, S. (1974). Hedonic prices and implicit markets: product differentiation in pure competition. *Journal of Political Economy*, 82(1), 34-55. <https://doi.org/10.1086/260169>
- Sánchez-Cabrera, D., González-Arias, J., y Rey-Blanco, D. (2024). Metodología de estimación del tiempo de venta a través de modelos de supervivencia. *Revista INVI*, 39(110), 164-202. <https://doi.org/10.5354/0718-8358.2024.69772>
- Seabold, S., y Perktold, J. (2010). *Statsmodels: Econometric and statistical modeling with Python*. *Proceedings of the 9th Python in Science Conference (SCIPY)*. <https://doi.org/10.25080/Majora-92bf1922-011>
- Shapley, L. S. (1953). Stochastic games. *Proceedings of the National Academy of Sciences*, 39(10), 1095-1100. <https://doi.org/10.1073/pnas.39.10.1095>
- Solano Sánchez, M. Á., Núñez, J. M., y Caridad Ocerín, J. M. (2021). Un modelo hedónico para los alquileres turísticos en la ciudad de Sevilla. *Revista de Métodos Cuantitativos para la Economía y la Empresa*, 31, 144-160. <https://doi.org/10.46661/revmetodoscuanteconempresa.4043>
- Štubňová, M., Urbaníková, M., Hudáková, J., y Papcunová, V. (2020). Estimation of residential property market price: Comparison of artificial neural networks and hedonic pricing model. *Emerging Science Journal*, 4(6), 530-538. <https://doi.org/10.28991/esj-2020-01250>
- Tchuente, D. y Nyawa, S. (2022). Real estate price estimation in French cities using geocoding and machine learning. *Annals of Operations Research*, 308(1), 571-608. <https://doi.org/10.1007/s10479-021-03932-5>
- United Nations. (2015). *Transforming our world: the 2030 agenda for sustainable development*. <https://sdgs.un.org/2030agenda>
- Yazdani, M. (2021). *Machine learning, deep learning, and hedonic methods for real estate price prediction*. arXiv. <https://doi.org/10.48550/arXiv.2110.07151>
- Zaragoza, A. e Ibáñez, R. (2024). Previsiones sobre la demanda de vivienda residencial en España para los próximos años. En S. Carbó Valverde (Coord.), *Mercado inmobiliario y política de la vivienda en España* (pp. 17-31). FUN-CAS. <https://www.funcas.es/libro/mercado-inmobiliario-y-politica-de-la-vivienda-en-espana/>

revista invi



Revista INVI es una publicación periódica, editada por el Instituto de la Vivienda de la Facultad de Arquitectura y Urbanismo de la Universidad de Chile, creada en 1986 con el nombre de Boletín INVI. Es una revista académica con cobertura internacional que difunde los avances en el conocimiento sobre la vivienda, el hábitat residencial, los modos de vida y los estudios territoriales. Revista INVI publica contribuciones originales en español, inglés y portugués, privilegiando aquellas que proponen enfoques inter y multidisciplinares y que son resultado de investigaciones con financiamiento y patrocinio institucional. Se busca, con ello, contribuir al desarrollo del conocimiento científico sobre la vivienda, el hábitat y el territorio y aportar al debate público con publicaciones del más alto nivel académico.

Director: Dr. Jorge Larenas Salas, Universidad de Chile, Chile.

Editor: Dr. Pablo Navarrete-Hernández, Universidad de Chile, Chile.

Editores asociados: Dra. Mónica Aubán Borrell, Universidad de Chile, Chile

Dr. Cristian Escobedo Catalán, Universidad de Chile, Chile

Dr. Gabriel Felmer, Universidad de Chile, Chile.

Dr. Carlos Lange Valdés, Universidad de Chile, Chile.

Dr. Daniel Muñoz Zech, Universidad de Chile, Chile.

Dra. Rebeca Silva Roquefort, Universidad de Chile, Chile

Coordinadora editorial: Sandra Rivera Mena, Universidad de Chile, Chile.

Asistente editorial: Katia Venegas Foncela, Universidad de Chile, Chile.

Traductor: Jose Molina Kock, Chile.

Diagramación: Ingrid Rivas, Chile.

Corrección de estilo: Leonardo Reyes Verdugo, Chile.

COMITÉ EDITORIAL:

Dra. Julie-Anne Boudreau, Universidad Nacional Autónoma de México, México

Dr. Victor Delgadillo, Universidad Autónoma de la Ciudad de México, México.

Dra. María Mercedes Di Virgilio, CONICET/ IIGG, Universidad de Buenos Aires, Argentina.

Dr. Ricardo Hurtubia González, Pontificia Universidad Católica de Chile, Chile.

Dra. Irene Molina, Uppsala Universitet, Suecia.

Dra. Raquel Rolnik, Universidade de São Paulo, Brasil

Dr. Javier Ruiz Sánchez, Universidad Politécnica de Madrid, España.

Dra. Elke Schlack Fuhrmann, Pontificia Universidad Católica de Chile, Chile.

Dr. Carlos Alberto Torres Tovar, Universidad Nacional de Colombia, Colombia.

Dr. José Francisco Vergara-Perucich, Universidad de Las Américas, Chile.

Sitio web: <http://www.revistainvi.uchile.cl/>

Correo electrónico: revistainvi@uchilefau.cl

Licencia de este artículo: Creative Commons Atribución-CompartirIgual 4.0
Internacional (CC BY-SA 4.0)